적응형 노이즈 주입형 차분 프라이버시 임베딩 기반의 보안 강화 검색 증강 생성

Adaptive Noise-Injected DP Embedding for Secure RAG

4조 12211484 박근채 / 12211849 최인규 / 12214194 전인서

I. 연구 동기

최근 대규모 언어 모델(Large Language Models, LLM)의 비약적인 발전으로, 많은 기업이 실무 프로젝트에 LLM 도입을 가속화하고 있다. 그러나 LLM은 학습 데이터에 의존한 추론 기반의 답변을 생성하는 특성상, 사실 관계와 다른 정보를 생성하는 **환각 현상(Hallucination)** 문제에 직면해 있다. 이러한 한계를 극복하고 답변의 신뢰도 및 정확성을 제고하기 위해, 외부 문서에서 관련 정보를 검색하여 답변 생성을 보조하는 **검색 증강 생성(Retrieval Augmented Generation, RAG)** 기법이 핵심 대안으로 부상하였다.

일반적으로 RAG 기법은 고차원 벡터 공간에서의 유사도 계산을 기반으로 하는 **밀집 검색(Dense Retrieval, DR)** 방식을 채택하여 관련 문서를 추출한다. 하지만 최근 임베딩 벡터로부터 원문 텍스트를 복원하는 Vec2Text와 같은 역공학 연구가 활발히 진행되면서, 90% 이상의 높은 유사도로 원문 데이터를 복구할 수 있음이 증명되었다.[link] 이는 벡터 DB 내에 저장된 데이터가 더 이상 안전하지 않음을 시사하며, 악의적인 **말뭉치 오염 공격(Corpus Poisoning Attack)**을 통한 민감 정보 및 개인정보 유출에 대한 보안 위협을 고조시키고 있다.[link]

임베딩 데이터를 보호하기 위한 기존의 단순 노이즈 주입 방식은 보안성은 높일 수 있으나, 벡터 간의 유사도 구조를 파괴하여 검색 정확도를 급격히 저하시키는 한계가 있다. 이에 본 연구에서는 임베딩 역공학 공격을 원천적으로 차단 하면서도 검색 성능 손실을 최소화하는 **차분 프라이버시 기반 임베딩 보호(DP-Embedding)** 기술을 제안한다.

단순한 가우시안 노이즈 주입에서 벗어나, 데이터의 특성에 따라 노이즈 강도를 동적으로 조절하는 **적응형 노이즈 스케일링(Adaptive Noise Scaling)** 기막을 통해 보안과 유틸리티 사이의 최적의 균형점(Trade-off)을 도출하고자 한다. 최종적으로 제안 기법을 적용한 모델과 표준 RAG 시스템 간의 성능 및 보안성 비교 분석을 통해, 데이터 무결성과 사용자 프라이버시가 완벽히 보장되는 차세대 보안 RAG 프레임워크의 효용성을 검증하고자 한다.

II. 해결하고자 하는 과제

1. 차분 프라이버시 기반 임베딩 보호 (DP-Embedding)

1-1. 고차원 벡터 공간의 위상 구조 파괴 및 검색 정확도 저하

임베딩 벡터 v에 노이즈 $\mathbf{z}$를 주입하는 **입력값 교란(Input Perturbation)** 방식을 설계할 때에, 단순 가우시안 노이즈 주입 방식($v' = v + \mathbf{z}$)은 구현이 용이하나, 고차원 공간의 특성상 심각한 성능 저하를 초래한다. 고차원 공간에서는 미세한 섭동만으로도 **벡터 간의 유클리드 거리(L2 Distance)**나 **코사인 유사도(Cosine Similarity)**가 비선형적으로 왜곡되며, 이는 질의 벡터와 문서 벡터 간의 상대적 순위를 뒤바꾸는 **랭킹 플립(Ranking Flip)** 현상을 야기한다. 결과적으로 RAG 시스템이 의미론적 유사성이 결여된 부적절한 문서를 추출하게 되어 **환각(Hallucination)** 발생률이 급증하고, 검색 정확도(Retrieval Recall)와 프라이버시 보호 수준 사이의 극심한 **트레이드오프(Trade-off)** 문제가 발생한다.

1-2. 성능 유지형 적응형 노이즈(Adaptive Noise Injection) 설계

1-2-1. 유사도 보존 임계값 기반 노이즈 스케일링

모든 차원에 균일한 노이즈를 더하는 대신, 검색 성능에 결정적인 영향을 미치는 상위 K개 결과의 일관성을 유지할 수 있도록 노이즈 강도 σ를 동적으로 산출한다. 이를 위해 벡터의 L2-norm 민감도를 실시간 분석하여 노이즈 주입 범위를 제한한다.

1-2-2. 적응형 프라이버시 예산(ϵ) 할당

고정된 노이즈를 사용하는 대신, 데이터의 군집 밀도(Cluster Density)에 따라 노이즈 강도를 조절한다. 밀집도가 높은 영역에서는 더 정밀한 노이즈를, 밀집도가 낮은 영역에서는 상대적으로 큰 노이즈를 적용하여 시멘틱 군집 내 이탈을 최소화한다.

1-2-3. 반복적 최적화(Iterative Optimization)

테스트 셋을 활용하여 노이즈 주입 후의 검색 정확도와 원문 복원 방지 성능을 상호 검증하며, 검색 정확도 저하 폭이 목표치를 초과하지 않는 최적의 프라이버시 예산 ϵ의 상한선을 도출한다.

III. 실험 및 검증 방법

1. 개발 스택

1-1. Environment

Equipment: Macbook M4 Pro
Language: Python 3.13.5
Package Manager: Poetry
Container: Docker & Docker Compose
IDE: Pycharm

1-2. Backend & Infra

Framework: FastAPI

Server: Uvicorn

Vector DB: Qdrant (Docker Image 사용)

LLM Engine: Ollama(Llama-3)

1-3. AI & Data Science

Deep Learning: PyTorch

Embedding: HuggingFace TransFormers

Model: BAAI/bge-m3

DataSet: 텍스트 복원이 민감한 금융(FiQA), 의료(PubMedQA) 오픈 데이터셋

FiQA: orgrctera/beir_fiqa

PubMedQA: CesarCEOAI/PubMedQA

Data Analysis:

1. Numpy - 적응형 노이즈(DP) 주입 행렬 연산용
2. Pandas - 데이터셋 로드 및 전처리용(CSV/JSON)

Differential Privacy: 직접 구현한 적응형 노이즈 주입 모듈 또는 diffprivlib

2. 주요 모듈별 상세 구현 프로세스

2-1. DP-Embedding: 적응형 노이즈 주입 모듈

단순 가우시안 노이즈의 한계를 극복하기 위해 **차원별 중요도 가중치**를 반영한 DP를 구현한다.

민감도 분석 (Sensitivity Analysis): 각 차원이 유사도 계산에 기여하는 정도를 편미분을 통해 계산하여, 중요도가 낮은 차원에 더 많은 노이즈를 배분한다.
클리핑(Clipping): 임베딩 벡터의 L2-norm을 특정 임계값 C로 클리핑하여 노이즈의 전파 범위를 제한한다.

구현 로직: 원본 임베딩 $\boldsymbol{v}$ 생성 후, $\boldsymbol{v}_{clipped}$ = $\boldsymbol{v}$ / max(1, $\frac{||\boldsymbol{v}||_2}{C}$) 수행. 차원별 분산 $\boldsymbol{\sigma}_i^2$을 조정하여 $\boldsymbol{v}$' = $\boldsymbol{v}_{clipped}$ + N(0, $\boldsymbol{\sigma}_i^2 I$) 적용

3. 성능 평가 지표

제안한 방법론의 효용성을 입증하기 위해 “Basic, Gausiaan Noise, Adaptive Noise” 3가지 종류에 대해 다음 세 가지 측면에서 지표를 산출한다.

3-1. Utility (검색 성능):

NDCG(Normalized Discounted Cumulative Gain): 검색 결과의 순위 정확도 평가

3-2. Privacy (보안 성능):

Inversion Success Rate: “Vec2Text” 공격 시 원문과의 문자열 유사도(BLEU/ROUGE score) 감소율

3-3. Efficiency (효율성):

Latency: 배치 쿼리 및 노이즈 연산으로 인한 응답 시간 증가 지연(ms)